ක්‍රියාවලිය • දත්ත • පරීක්ෂාව • සීමාවන්

ස්ථාන ආසන්නතාව සහ රෝග නිරාවරණය

පරිශීලකයන් 100 දෙනෙකුගේ කෘත්‍රිම Matara dataset එකක් මත කළ coordinate matching සහ machine-learning model comparison වාර්තාව.

වාර්තා දිනය: 2026 ඔක්තෝබර් 20 · භාෂාව: සිංහල

100	6	4
කෘත්‍රිම පරිශීලකයන්	රෝග කාණ්ඩ	පරීක්ෂා කළ models

ප්‍රධාන ප්‍රතිඵලය

පරීක්ෂා කළ settings යටතේ Logistic Regression එකට වැඩිම test accuracy (79.4%) සහ Macro F1 (23.7%) ලැබුණා. එහෙත් සරල baseline එකේ accuracy එකත් 78.9% නිසා මෙය ශක්තිමත් රෝග පුරෝකථන සාක්ෂියක් නොවෙයි.

අප කළ ක්‍රියාවලිය

1. රෝග හය සහ medical-history fields තෝරාගත්තා.
2. පළමු area-level sample එකට latitude/longitude සහ කාල වාර්තා එකතු කළා.
3. එකම කාලයේ ආසන්නව සිටි පරිශීලක යුගල සහ කෘත්‍රිම රෝග නිරාවරණ දත්ත සෑදුවා.
4. එකම training/test බෙදීම මත models හතරක් පුහුණු කර, baseline එකක් සමඟ සසඳා බැලුවා.

මෙහි අගයන් අවසාන coordinate-based dataset එකට අදාළයි. පැරණි area-only dataset එකේ ප්‍රතිඵල මේ අවසාන ප්‍රතිඵල සමඟ මිශ්‍ර කර නැහැ.

සැබෑ රෝගීන්, සැබෑ GPS tracks හෝ සැබෑ outbreak වාර්තා මෙයට භාවිත කර නැහැ. Diagnosis, ආසාදන සම්භාවිතාව හෝ prescription සඳහා මේ model එක තහවුරු කර නැහැ.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

Dataset එකේ අන්තර්ගතය

රෝග: **Influenza, Chickenpox, Measles, Mumps, Viral conjunctivitis සහ Viral gastroenteritis.** ප්‍රදේශ: මාතර නගරය, වැලිගම, අකුරැස්ස, දික්වැල්ල, හක්මන සහ කඹුරුපිටිය.

දත්ත ගොනුව	වාර්තා	අන්තර්ගතය
users.csv	100	වයස, home area සහ කෘත්‍රිම medical history
location_visits.csv	2800	Latitude/longitude, accuracy, start/end time
location_anchors.csv	6	ආසන්න synthetic town anchors
proximity_pairs.csv	1841	ආසන්නව එකවර සිටි user pairs
ble_encounters.csv	91	Pairs කිහිපයක කෘත්‍රිම BLE observations
source_infection_episodes.csv	157	පෙර දැන සිටි කෘත්‍රිම ආසාදන වාර්තා
pair_disease_exposure.csv	22092	Pair × දිශා දෙක × රෝග හය
area_disease_reports.csv	144	ප්‍රදේශ × රෝග × සති 4
dataset_100_users.csv	100	Model features සහ outcome labels හය
outcomes.csv	600	User × රෝග අනුව simulated outcomes

කාල සීමාව සහ labels

Prediction cutoff: **2026-09-01 00:00, Asia/Colombo.** ඊට පෙර දින 28ක visits භාවිත කළා. ඊළඟ දින 28 සඳහා outcomes නිර්මාණය කළා; follow-up අවසානය 2026-09-29 00:00යි.

එක් රෝගයකට **1 = simulated positive** සහ **0 = simulated negative**. එක් user කෙනෙකුට කිසිදු රෝගයක් නැති හෝ රෝග එකක්/කිහිපයක් ඇති labels ලැබිය හැකියි. මේවා වෛද්‍ය පරීක්ෂණවලින් ලැබුණු diagnoses නොවෙයි.

Medical-history inputs

වයස (5–80), immunocompromised status, chronic respiratory history, MMR doses (0–2), varicella immunity history සහ recent influenza vaccination කෘත්‍රිමව නිර්මාණය කළා. මේ බෙදාහැරීම් ශ්‍රී ලංකාවේ සැබෑ ජනගහනය නියෝජනය නොකරයි.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

Coordinates දෙකක් සසඳන ආකාරය

Latitude / Longitude → Haversine distance → Time overlap → Historical source episode → Exposure features

1. Users දෙදෙනාගේ latitude/longitude අතර දුර මීටර්වලින් ගණනය කළා.
2. එම visits දෙකේ එකවර රැඳී සිටි කාලය ගණනය කළා.
3. **දුර ≤ 50 m සහ overlap ≥ 5 min** වූ යුගල තෝරාගත්තා. මේවා වෙනස් කළ හැකි search settings; වෛද්‍ය transmission සීමාවන් නොවෙයි.
4. එක් එක් රෝගයට A → B සහ B → A දෙදිශාවම සසඳා බැලුවා.

Generated dataset එකෙන් උදාහරණයක්: PAIR56

User	Latitude	Longitude	Simulated GPS accuracy
SYN008	6.078063	80.564512	17 m
SYN020	6.078126	80.564476	15 m

Measured distance: **8.057199 m** · overlap: **44 minutes**. Accuracy radii එකතු කළ විට illustrative distance bounds **0–40.057199 m**. මේ pair එකට BLE observation එකක් නැහැ.

SYN020 සඳහා එම encounter කාලයට අදාළ, පෙර report කළ කෘත්‍රිම chickenpox episode එකක් තිබෙනවා. SYN008 සඳහා ලැබුණු toy exposure index එක **0.490164**යි. එය **49% ආසාදන සම්භාවිතාවක් නොවෙයි.**

භාවිත කළ පරීක්ෂණ සූත්‍රය

```
infectious_overlap_hours × exp(-distance_m / 20)
× context_weight × (1 - 0.6 × simplified_immunity)
```

Context flags: same indoor space, shared-food contact, hand/surface contact. මේවා GPS එකෙන් හඳුනාගත්තේ නැහැ; වෙනම simulate කළා. රෝග අනුව context weight යෙදුවත් එහි coefficients වෛද්‍යමය වශයෙන් තහවුරු කර නැහැ.

> Source episode එක encounter එකට පෙර report වී තිබිය යුතුයි. පසුව ලැබුණු outcome label එකකින් අතීත ආසාදිත බව තීරණය කළේ නැහැ. Unknown status කියන්නේ “ආසාදනයක් නැහැ” කියන තේරුම නොවෙයි.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

Training සහ evaluation සැකසුම්

70	30	0.5
Training users	Held-out test users	Decision threshold

එක් model වර්ගයකට රෝග හය සඳහා binary classifiers හයක් පුහුණු කළා. Models සියල්ලටම එකම users, එකම feature definitions සහ එකම threshold භාවිත කළා. Test users training එකට ඇතුළත් කළේ නැහැ.

Model	ස්ථාවර settings
Logistic Regression	L2 = 0.1; 2,000 gradient steps; learning rate 0.08
Random Forest	300 trees; max depth 4; minimum leaf samples 3
XGBoost	200 trees; depth 2; learning rate 0.03; lambda 5; min child weight 3
CatBoost	200 iterations; depth 3; learning rate 0.03; L2 leaf regularization 5
Majority baseline	රෝගයක් සඳහා training data එකේ වැඩිම label එක predict කිරීම

Feature selection සහ data leakage පාලනය

History, visit/indoor/BLE hours, nearby-user counts, pair-contact hours, area exposure සහ disease-specific contact features භාවිත කළා. User IDs, absolute coordinates සහ future outcomes predictors ලෙස භාවිත කළේ නැහැ. Logistic Regression scaling fit කළේ training data මත පමණයි.

අමතර පරීක්ෂාව

Training users 70 තුළ three-fold out-of-fold validation කළා. Macro F1 අනුව exploratory model selection කළා. Hyperparameter search, class weighting හෝ threshold tuning කළේ නැහැ. මෙය එක් එක් algorithm එකේ හැකි උපරිම performance එක පරීක්ෂා කිරීමක් නොවෙයි.

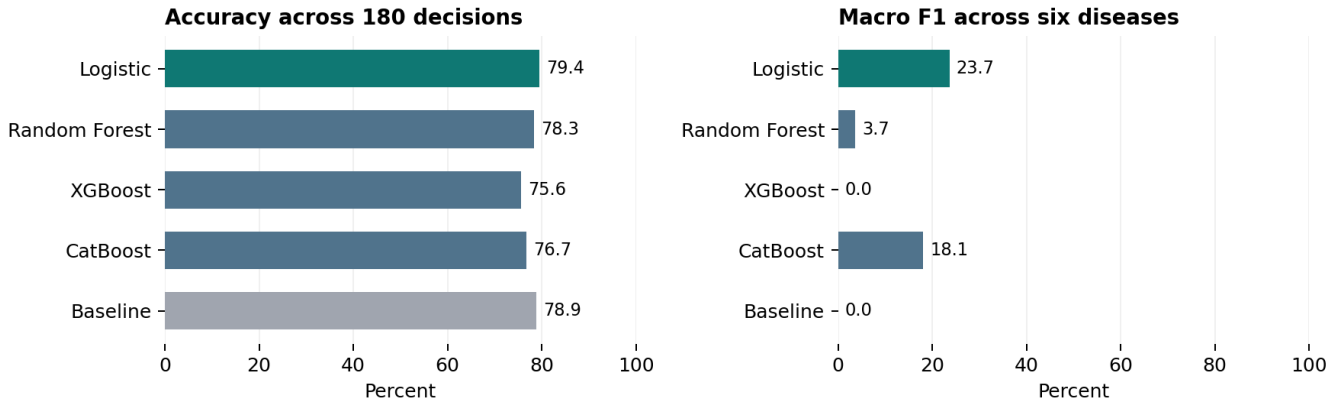
> Original JavaScript Logistic Regression predictions සහ Python implementation එකේ predictions අතර වෙනස 10^{-8} සීමාව තුළ බව assert කළා. Random Forest, XGBoost සහ CatBoost සඳහා සැබෑ library implementations භාවිත කළා.

Python 3.13.7 · NumPy 2.2.6 · scikit-learn 1.6.1 · XGBoost 3.0.2 · CatBoost 1.2.8. Model seed: 42; split seed: 731. LLM එකක් train හෝ evaluate කළේ නැහැ.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

සමස්ත model comparison ප්‍රතිඵල

Model	Accuracy	Balanced acc.	Macro recall	Macro F1	CV F1
Logistic Regression	79.4%	58.0%	20.2%	23.7%	18.6%
Random Forest	78.3%	50.5%	2.4%	3.7%	9.5%
XGBoost	75.6%	48.0%	0.0%	0.0%	9.7%
CatBoost	76.7%	52.9%	11.8%	18.1%	17.7%
Majority baseline	78.9%	50.0%	0.0%	0.0%	0.0%



Logistic Regression එකට මේ test set එකේ වැඩිම accuracy සහ F1 ලැබුණා. Training-only CV Macro F1 එකත් **18.6%** ලෙස models අතර ඉහළම අගයයි.

> **79.4% accuracy එක පමණක් ප්‍රමාණවත් නොවන්නේ ඇයි?**
>
> Test users 30 × රෝග 6 = තීරණ 180යි. Logistic Regression නිවැරදි තීරණ **143ක්** දුන් අතර baseline එක **142ක්** දුන්නා. එනම් වෙනස එක් නිවැරදි තීරණයක් පමණයි. රෝග-positive අවස්ථා හඳුනාගැනීම තවම දුර්වලයි.

Accuracy: නිවැරදි තීරණ ප්‍රතිශතය. **Recall:** positive අවස්ථාවලින් හඳුනාගත් ප්‍රතිශතය. **F1:** precision සහ recall එකට සලකන මිනුම. **Macro:** රෝග හයට සමාන බරක් දී ගත් සාමාන්‍යය. **Balanced accuracy:** sensitivity සහ specificity සාමාන්‍යය.

Logistic Regression හි සියලු රෝග හයේ predictions එකවර නිවැරදි වූ users: **7 / 30 (23.3%)**. මෙය 79.4% label accuracy එකෙන් වෙනස් මිනුමකි.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

රෝග අනුව ප්‍රතිඵල — 1

සෑම රෝගයකටම test users 30 දෙනාම භාවිත කළා. මේ positive counts සැබෑ රෝග ව්‍යාප්තිය නොව කෘත්‍රිම labels වේ.

Influenza — positive 6 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	83.3%	66.7%	33.3%	44.4%	23 / 1 / 4 / 2
Random Forest	80.0%	0.0%	0.0%	0.0%	24 / 0 / 6 / 0
XGBoost	80.0%	0.0%	0.0%	0.0%	24 / 0 / 6 / 0
CatBoost	86.7%	100.0%	33.3%	50.0%	24 / 0 / 4 / 2
Majority baseline	80.0%	0.0%	0.0%	0.0%	24 / 0 / 6 / 0

Chickenpox — positive 11 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	66.7%	100.0%	9.1%	16.7%	19 / 0 / 10 / 1
Random Forest	63.3%	0.0%	0.0%	0.0%	19 / 0 / 11 / 0
XGBoost	63.3%	0.0%	0.0%	0.0%	19 / 0 / 11 / 0
CatBoost	66.7%	100.0%	9.1%	16.7%	19 / 0 / 10 / 1
Majority baseline	63.3%	0.0%	0.0%	0.0%	19 / 0 / 11 / 0

Measles — positive 3 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	90.0%	0.0%	0.0%	0.0%	27 / 0 / 3 / 0
Random Forest	90.0%	0.0%	0.0%	0.0%	27 / 0 / 3 / 0
XGBoost	90.0%	0.0%	0.0%	0.0%	27 / 0 / 3 / 0
CatBoost	90.0%	0.0%	0.0%	0.0%	27 / 0 / 3 / 0
Majority baseline	90.0%	0.0%	0.0%	0.0%	27 / 0 / 3 / 0

> **Measles ප්‍රතිඵලයේ පාඩම**
>
> Accuracy 90% වුවත් models සියල්ලම positive අවස්ථා තුනම මගහැරියා. ඒ නිසා accuracy ඉහළ යාම පමණක් රෝග හඳුනාගැනීමේ හැකියාව තහවුරු කරන්නේ නැහැ.

TN: නිවැරදි negative · FP: වැරදි positive · FN: මගහැරුණු positive · TP: නිවැරදි positive.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

රෝග අනුව ප්‍රතිඵල — 2

Mumps — positive 7 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	76.7%	0.0%	0.0%	0.0%	23 / 0 / 7 / 0
Random Forest	76.7%	0.0%	0.0%	0.0%	23 / 0 / 7 / 0
XGBoost	76.7%	0.0%	0.0%	0.0%	23 / 0 / 7 / 0
CatBoost	80.0%	100.0%	14.3%	25.0%	23 / 0 / 6 / 1
Majority baseline	76.7%	0.0%	0.0%	0.0%	23 / 0 / 7 / 0

Viral conjunctivitis — positive 4 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	83.3%	40.0%	50.0%	44.4%	23 / 3 / 2 / 2
Random Forest	83.3%	0.0%	0.0%	0.0%	25 / 1 / 4 / 0
XGBoost	76.7%	0.0%	0.0%	0.0%	23 / 3 / 4 / 0
CatBoost	70.0%	0.0%	0.0%	0.0%	21 / 5 / 4 / 0
Majority baseline	86.7%	0.0%	0.0%	0.0%	26 / 0 / 4 / 0

Viral gastroenteritis — positive 7 / 30

Model	Accuracy	Precision	Recall	F1	TN / FP / FN / TP
Logistic Regression	76.7%	50.0%	28.6%	36.4%	21 / 2 / 5 / 2
Random Forest	76.7%	50.0%	14.3%	22.2%	22 / 1 / 6 / 1
XGBoost	66.7%	0.0%	0.0%	0.0%	20 / 3 / 7 / 0
CatBoost	66.7%	20.0%	14.3%	16.7%	19 / 4 / 6 / 1
Majority baseline	76.7%	0.0%	0.0%	0.0%	23 / 0 / 7 / 0

එක් test user කෙනෙකුගේ label එකක් නිවැරදි/වැරදි වීමෙන් අදාළ රෝගයේ accuracy එක 3.33 percentage points කින් වෙනස් වෙනවා. Sample එක කුඩා නිසා රෝගයක් සඳහා ලැබුණු සුළු වෙනසක් ස්ථිර model superiority එකක් ලෙස සලකන්න බැහැ.

XGBoost හි threshold 0.5 යටතේ Macro Recall = 0%. එහෙත් probability ranking මනින Macro AP = 41.9%යි. Threshold-based classification සහ score ranking වෙනස් දේවල්; මෙහි threshold එක test data මත වෙනස් කළේ නැහැ.

පර්යේෂණ ක්‍රියාවලිය සහ ප්‍රතිඵල

නිර්දේශය, සීමාවන් සහ නැවත ධාවනය

> **Prototype සඳහා නිර්දේශය: Logistic Regression baseline එක තබාගන්න.**
>
> මේ නිශ්චිත settings සහ dataset එකේ එයට වඩා හොඳ accuracy/F1 ලැබුණා. එහෙත් කිසිදු model එකක් මේ ප්‍රතිඵල මත diagnosis හෝ prescription සඳහා භාවිත නොකළ යුතුයි.

- **Synthetic labels:** coefficients, source episodes සහ outcomes නිර්මාණය කළ ඒවායි. රෝග හයට එකම කෘත්‍රිම දින 7ක infectious window එක යොදාගත්තා; එය clinical estimate එකක් නොවෙයි.
- **GPS සීමාව:** stationary coordinate එකක් visit එක පුරා උපකල්පනය කළා. Position error, walls, floors, ventilation සහ source පිටවූ පසු airborne exposure සම්පූර්ණයෙන් model කළේ නැහැ.
- **Validation සීමාව:** test users 30ක් පමණයි. Users අතර shared contacts තිබෙන නිසා split එක network-disjoint හෝ time-disjoint නොවෙයි. Test set එක පෙර බැලූ නිසා මේ comparison එක exploratory යි.
- **Next step:** consented real data, verified historical reports සහ clinical outcomes එකතු කර, training-only tuning කර, අලුත් untouched temporal/network test set එකක පරීක්ෂා කරන්න.

නැවත ධාවනය කිරීම

```
node scripts/matara-ml.cjs
python -m pip install -r research/model-comparison-requirements.txt
python scripts/compare-matara-models.py
```

Python commands සඳහා isolated environment එක භාවිත කරන්න. Exact versions, parameters, predictions සහ SHA-256 hashes `model-comparison/comparison.json` තුළ ඇත. Dataset වෙනස් කළ පසු comparison එක නැවත ධාවනය කළ යුතුයි.

සත්‍යාපනය සහ මූලාශ්‍ර

Project tests 24 සමත්. Typecheck සමත්. Lint: errors 0; කලින් තිබූ warnings 3. Library dependencies පරීක්ෂාව සමත්. දත්ත external inference සේවාවකට යවා නැහැ; prescription component එකට මේ models සම්බන්ධ කර නැහැ.

Background references (මේවා synthetic coefficients සඳහා මූලාශ්‍ර නොවෙයි):
CDC — Measles clinical overview · CDC — Conjunctivitis · CDC — Norovirus
Sri Lanka Epidemiology Unit — Weekly reports
CatBoost documentation · XGBoost documentation · scikit-learn metrics